



BOOKLIZER

Um aplicativo de recomendação literária personalizada usando GNN

Gabriella Silveira Braz - e-mail: 10402554@mackenzista.com.br

Giovana Liao - e-mail: 10402264@mackenzista.com.br

Maria Julia de Pádua - e-mail: 10400630@mackenzista.com.br

Orientador:

Ivan Carlos Alcântara de Oliveira - e-mail: ivan.oliveira@mackenzie.br

Sumário

1. Introdução

2. Referencial Teórico

3. Metodologia

4. Resultados

5. Conclusão

6. Referência Bibliográfica

Introdução

Um fenômeno cultural em transformação

- Dispositivos móveis e redes sociais mudaram o ato de ler.
- Leitura tornou-se uma prática social com compartilhamento de opiniões e comunidades online.

Influência das redes

- **28%** dos leitores brasileiros foram influenciados por TikTok, YouTube e Instagram.
- **60%** dos jovens (10–29 anos) seguem **influenciadores literários** (Instituto Pró-Livro, 2022).
- Comunidades como **BookTok** e **Bookgram** atuam como curadores de leitura (Maddox & Gill, 2023).

Objetivo

- Criar uma solução baseada em *Graph Neural Networks* (GNN) para modelar as relações entre livros e preferências dos usuários;
- Fornecer recomendações customizadas a cada perfil de usuário;
- Desenvolver um aplicativo que centralize o público leitor com uma interface responsiva;



Referencial Teórico

Sistemas de Recomendação

- Surgem para lidar com sobrecarga de informações (Adomavicius & Tuzhilin, 2005)
- Baseiam-se em interações usuário-item (Batmaz et al., 2019)
- Desafios: cold start, esparsidade e diversidade das sugestões (Kouki et al., 2023)
- Abordagens:
 - Filtragem baseada em conteúdo
 - Filtragem colaborativa
 - Métodos híbridos

Grafos

- Grafos representam relações entre entidades (Costa, 2011)
- Podem ser simples, homogêneos ou heterogêneos
- Grafos heterogêneos representam melhor dados reais (Chairatanakul, 2025)
- No Booklizer: grafo heterogêneo conectando livros, autores e gêneros

Graph Neural Networks (GNNs)

- Modelos de aprendizado profundo.
- Processam dados não euclidianos estruturados em grafos (Wu et al., 2021).
- Capturam relações entre nós por meio da propagação de mensagens (Zhou et al., 2018).
- Inspiradas em redes convolucionais, são aplicadas em variadas tarefas como classificação.

Comparativo com Souza & Souza (2021)

- Estudo propõe arquitetura híbrida com DNN: aspectos colaborativos + conteúdo.
- Nosso projeto: foco em estrutura relacional (GNN).
 - Aproveita topologia do grafo
 - Favorece propagação semântica entre nós
 - Abordagem mais estruturada e flexível



Metodologia



1. Levantamento de Requisitos

- **Funcionais:** cadastro de usuários, recomendação de livros, organização em estantes (“Tenho interesse” / “Já lido”), histórico de leitura, busca por livros.
- **Não funcionais:** interface responsiva, segurança e privacidade, boa performance, compatibilidade mobile.
- **Análise de mercado:** revisão de Goodreads e Skoob.

2. Prototipagem e Desenvolvimento

- Prototipagem no Figma para validar design e usabilidade.
- Implementação das interfaces no Flutter/Dart: navegação, exibição de recomendações, perfil do usuário, estantes, busca, seleção de gêneros.




Figura 1 – Top 25 gêneros das obras.

3. Obtenção de Dados

- API's como **OpenLibrary**, **Google Books** e **ISBN** foram avaliadas, mas apresentaram inconsistências de gênero e falta de padronização.
- Optou-se pela base **Best Books (10k) Multi-Genre Data (Kaggle, 2021)**, contendo títulos, autores, descrição, gêneros e avaliações.
- Limpeza e filtros aplicados:
 - Remoção de duplicatas, autores anônimos e livros sem gêneros.
- **Resultado:** 8.915 livros válidos.
- Exploração inicial dos dados identificou **616 gêneros**, sendo mais frequentes: Fiction, Nonfiction, Fantasy e Classics.

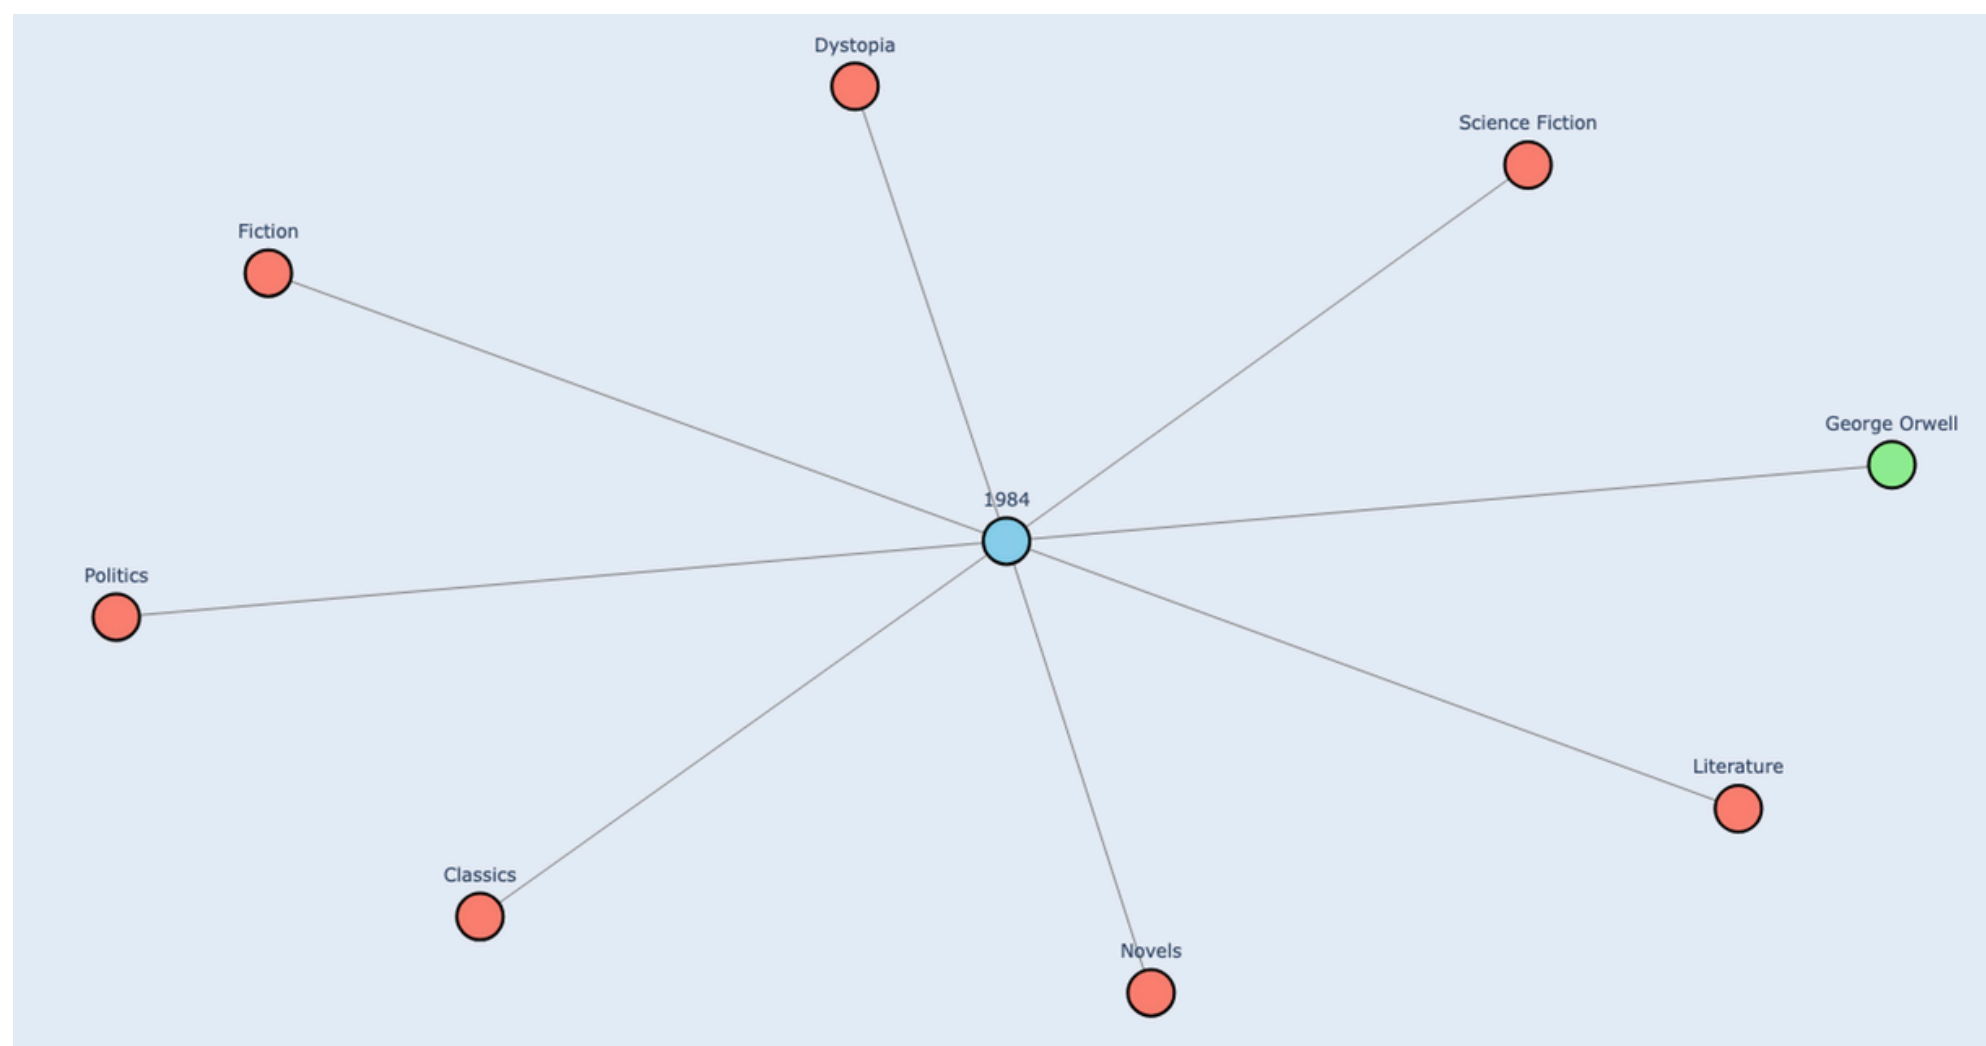


Figura 2 – Representação do grafo com nós do livro "1984", seus gêneros e autores.

4. Modelagem em grafos

- Construído grafo **heterogêneo** com três tipos de nós:
 - **Livros** (993), **Autores** (671), **Gêneros** (286).
- Arestas representavam relações **livro-autor** e **livro-gênero**.
- Estrutura final:
 - **1.950** nós
 - **15.656** arestas
 - Sem nós isolados.

5. Arquitetura GNN

- Modelo de recomendação baseado em GNN aplicada a grafo heterogêneo, integrando livros, autores e gêneros.
- **Versão inicial:**
 - Nós: livros + gêneros
 - Arquitetura: 2 camadas GCNConv (dimensões $24 \rightarrow 16$)
 - Entradas: one-hot dos nós
 - Treinado com Triplet Margin Loss por 60 épocas
 - Perda reduziu de 0,7370 \rightarrow 0,2209
- **Versão aprimorada:**
 - Inclusão de nós de autores
 - Uso de HeteroConv + SAGEConv para agregação intertipos
 - Dimensões: 24 (intermediária) e 64 (saída)
 - Produziu embeddings mais expressivos e recomendações mais precisas
- Modelo aprende padrões semânticos a partir das conexões no grafo, permitindo identificar similaridades literárias mesmo sem relações explícitas.

6. Treinamento

- Triplet Margin Loss usando:
 - Âncora = livro, Positivo = livro semelhante (autor/gênero), Negativo = não relacionado.
 - Otimizador Adam para atualização adaptativa dos embeddings.
- Embeddings resultantes usados para calcular similaridades e gerar recomendações personalizadas.

7. Geração de recomendações;

- Embeddings comparados com similaridade cosseno (valores de -1 a 1).
- Matriz quadrada.

8. Arquitetura do Sistema

- **Frontend:** App Mobile em Flutter.
- **Backend:** FastAPI.
- **Modelo GNN:** carregado em memória com cache.
- API retorna recomendações para renderização no app.

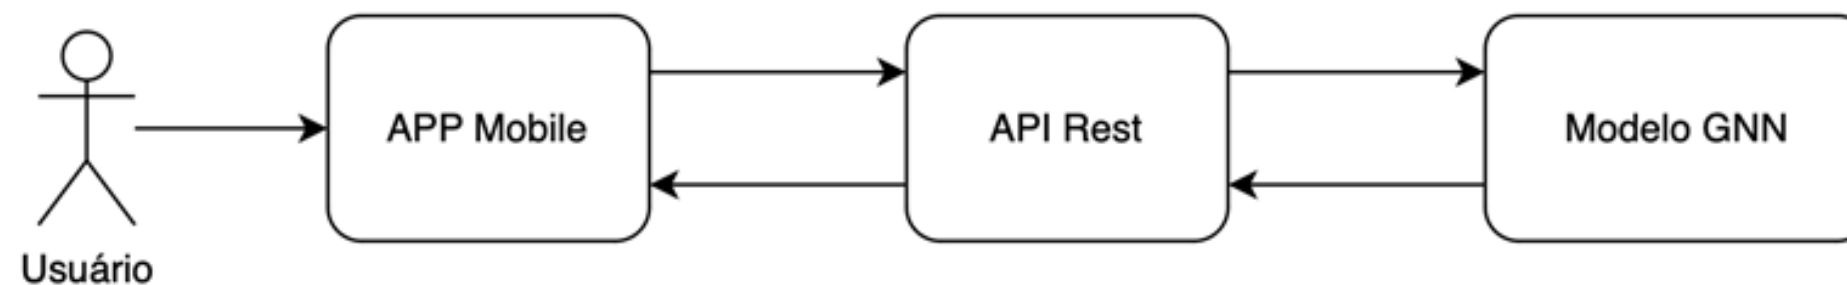


Figura 2– Arquitetura do Booklizer.

Fluxo geral:

Requisitos → Prototipagem → Implementação → Preparação de Dados → Treinamento GNN → Integração via API → App Mobile



9. Desenvolvimento da API

A API possui dois endpoints principais:

- **/livros/filtrar** – retorna a lista inicial de livros com base nos gêneros escolhidos, aplicando limpeza e padronização dos dados.
- **/recomendar** – gera recomendações personalizadas a partir de um livro âncora, utilizando a matriz de similaridade derivada dos *embeddings* da GNN.



Resultados


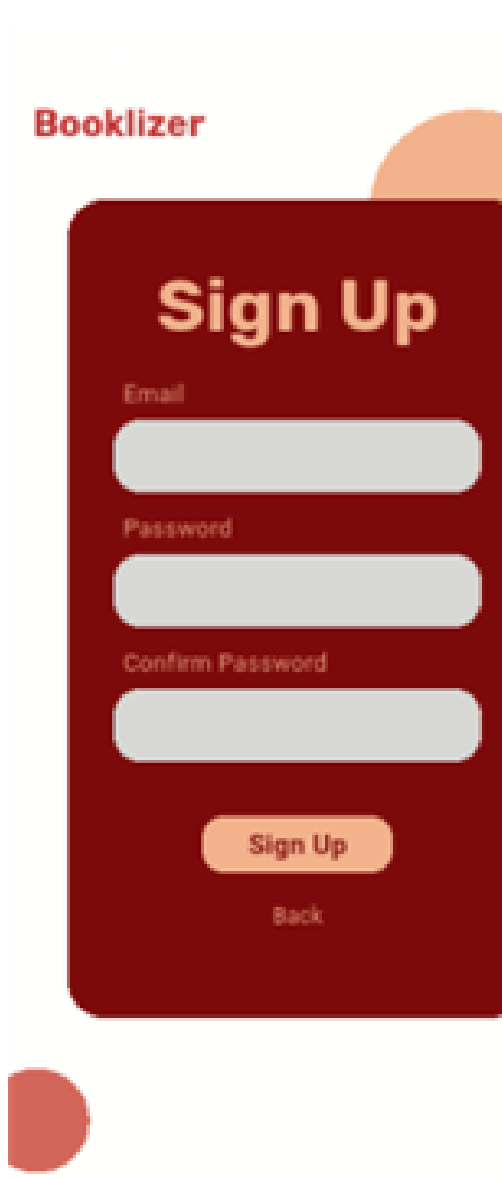



Figura 3 - Implementação das telas: Inicial, Cadastro, Login, Seleção de gêneros

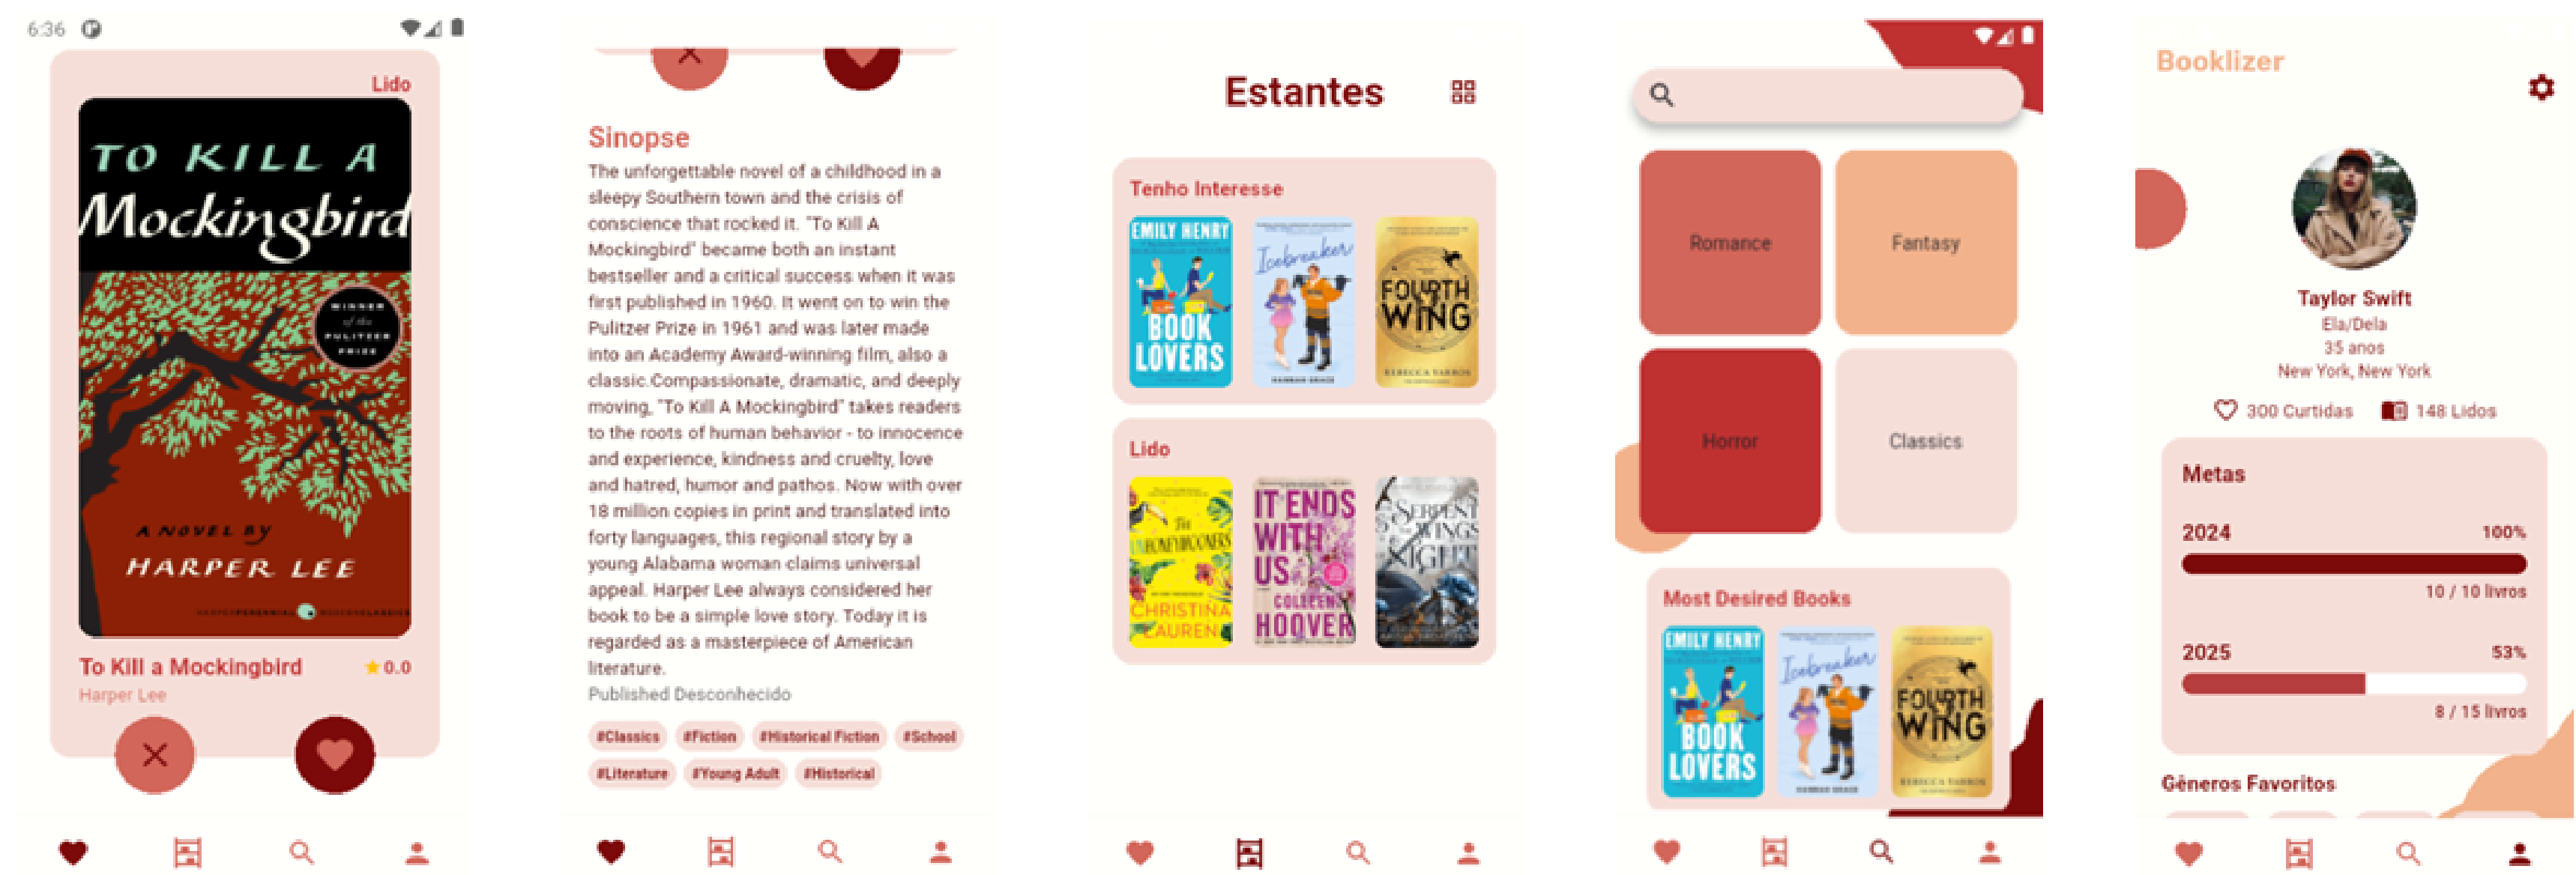



Figura 4 - Implementação das telas: Recomendação, Estantes, Busca e Perfil

1. Visualização dos Embeddings (Figura 4 – esquerda)

- Cada ponto representa um livro.
- Proximidade entre pontos reflete similaridade semântica.
- Formação de clusters coesos (comunidades literárias).
- **Destaques:**
 - **Círculo preto:** comunidade.
 - **Triângulos pretos:** outliers (temática distinta, múltiplos gêneros, estilo atípico).



2. Exemplo de Recomendação (Figura 4 – direita)

- **Livro âncora:** The Little Prince.
- **Recomendações mais próximas:**
 - a. The Story of a Seagull and the Cat Who Taught Her to Fly
 - b. Perrault's Fairy Tales
 - c. The Jungle Book
 - d. Ronia, the Robber's Daughter
 - e. Tales from the Perilous Realm (cluster diferente).




Figura 4 – Visualização 2D dos Embeddings dos Livros (à esquerda) e do modelo de recomendação (à direita).

3. Desempenho do Modelo de Recomendação

- O grafo heterogêneo utilizado contém 1.950 nós (993 livros, 671 autores e 286 gêneros) e 15.656 arestas, sem nós isolados.
- A comparação entre os modelos mostrou evolução significativa ao incluir autores como novo tipo de nó:
 - O modelo inicial (livros + gêneros) teve bom desempenho, mas limitado pela falta de relações autorais.
 - O modelo atual (livros + gêneros + autores) obteve métricas muito superiores, capturando padrões semânticos mais ricos e produzindo recomendações mais precisas.

Métrica	Modelo Inicial (Livros + Gêneros)	Modelo Atual (Livros + Gêneros + Autores)
Épocas de Treinamento	60	30
Função de Perda Inicial	0,7370	0,9971
Função de Perda Final	0,2209	0,2522
Precision@10	0,6795	0,994
Recall@10	1,0636	0,016
HitRate@10	1,0000	1,000
MAP@10	0,8655	0,993
NDCG@10	0,9310	0,995

Tabela 1 - Comparativos entre as métricas obtidas a partir dos modelos

Conclusão

Desenvolvimento até o momento:

- **Interfaces do app Booklizer** foram projetadas com base nos requisitos funcionais.
- Utilizado um dataset com **8.915 livros e 616 gêneros** → gerado grafo bipartido com:
 - 1.950 nós
 - 15.656 arestas
- Modelo GNN gerado com uma arquitetura composta por camadas HeteroConv combinadas com SAGEConv.

Potencial:

- Resultados indicam potencial bastante satisfatório para recomendações precisas e personalizadas.
- Espera-se transformar a forma de descobrir livros, promovendo o hábito de leitura de maneira: Personalizada, Interativa e Centrada nos interesses dos leitores

Próximas etapas:

- Criar banco de dados com usuários, livros e interações
- Incluir novos atributos de recomendação (descrição etc.)
- Aumentar a profundidade da GNN (mais camadas)
- Realizar mais testes e experimentos

CERTIFICATE

This is to certify that the paper entitled “**Booklizer - Um Aplicativo de Recomendação Literária Personalizada Usando GNN,**” authored by **Gabriella Silveira Braz, Giovana Liao, Maria Julia de Pádua and Ivan Carlos Alcântara de Oliveira**, was presented at ISLA 2025 – the *Information Systems in Latin America Conference*, an ancillary event to AMCIS 2025, the *Americas Conference on Information Systems*. This international event was organized by LACAIS, the Latin American and Caribbean Chapter of the Association for Information Systems (AIS), and took place online from August 11 to 13, 2025.

This paper was recognized as one of the recipients of the Best Research-in-Progress Paper Award at ISLA 2025.



Jose Pineda
José Pineda Delgado
California State University, USA

Alexandre Reis Graeml
Alexandre Reis Graeml
Universidade Tecnológica Federal do
Paraná, Brazil

Scientific Program Co-chairs – ISLA2025

Referência Bibliográfica

- ABDELRAHMAN, M. et al. Triplet loss for learning fine-grained image similarity. arXiv preprint arXiv:2107.06187 [cs.CV], 2021. Disponível em: <https://doi.org/10.48550/arXiv.2107.06187>. Acesso em: 30 out. 2025.
- ADOMAVICIUS, G.; TUZHILIN, A. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. IEEE Transactions on Knowledge and Data Engineering, v. 17, n. 6, p. 734–749, 2005.
- ALBRECHTSLUND, A. M. B. Amazon, Kindle, and Goodreads: implications for literary consumption in the digital age. Consumption Markets & Culture, v. 23, n. 6, p. 553–568, 2019. DOI: 10.1080/10253866.2019.1640216.
- AMARAL, Adriana; SALVADOR, Tarciso. Folksonomia em sites de redes sociais segmentadas (SRSS) em livros: um estudo exploratório da interface do Goodreads. RDBCI: Revista Digital de Biblioteconomia e Ciência da Informação, Campinas, SP, v. 16, n. 2, p. 397–413, 2018. DOI: 10.20396/rdbci.v16i2.8650424.
- BATMAZ, Z.; KALELI, C.; DOĞRU, İ. A.; YILDIRIM, Y. A review on deep learning for recommender systems: challenges and remedies. Artificial Intelligence Review, v. 52, n. 3, p. 1871–1939, 2019.
- CHAIRATANAKUL, N.; LIU, X.; HOANG, N. T. et al. Heterogeneous graph embedding with single-level aggregation and infomax encoding. Machine Learning, v. 112, p. 4227–4256, 2023. DOI: 10.1007/s10994-022-06160-5.
- COSTA, Polyanna Possani da. Teoria dos grafos e suas aplicações. 2011. 77 f. Dissertação (Mestrado em Matemática) — Universidade Estadual Paulista, Instituto de Geociências e Ciências Exatas, Rio Claro, 2011.
- JERASA, Shannon; BOFFONE, Trevor. BookTok 101: TikTok, Digital Literacies, and Out-of-School Reading Practices. Journal of Adolescent & Adult Literacy, v. 65, n. 3, p. 219–226, 2021. DOI: 10.1002/jaal.1199.
- KHEMANI, B.; PATIL, S.; KOTTECHA, K. et al. A review of graph neural networks: concepts, architectures, techniques, challenges, datasets, applications, and future directions. Journal of Big Data, v. 11, p. 18, 2024. DOI: 10.1186/s40537-023-00876-4.
- KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. In: 3rd International Conference for Learning Representations (ICLR), San Diego, 2015. Disponível em: <https://doi.org/10.48550/arXiv.1412.6980>. Acesso em: 30 out. 2025.
- KOUKI, P.; SINHA, R.; EKSTRAND, M. D. Challenges in responsible recommender systems. arXiv preprint arXiv:2306.12680, 2023.
- MADDOX, Jenny; GILL, Fiona. Assembling “Sides” of TikTok: Examining Community, Culture, and Interface through a BookTok Case Study. Social Media + Society, v. 9, n. 4, 2023. DOI: 10.1177/20563051231213565.
- MURRAY, Simone. Secret agents: algorithmic culture, Goodreads and datafication of the contemporary book world. European Journal of Cultural Studies, v. 24, n. 4, p. 970–989, 2021. DOI: 10.1177/1367549419886026.
- PAVLOPOULOS, G. A. et al. Using graph theory to analyze biological networks. BioData Mining, v. 4, n. 10, 2011. DOI: 10.1186/1756-0381-4-10.
- THELWALL, Mike; KOUSHA, Kayvan. Goodreads: a social network site for book readers. Journal of the Association for Information Science and Technology, v. 68, n. 4, p. 972–983, 2017. DOI: 10.1002/asi.23733.
- W3SLLEY. Bookcover API. 2024. Disponível em: <https://github.com/w3slley/bookcover-api>
- WU, Z.; PAN, S.; CHEN, F.; LONG, G.; ZHANG, C.; YU, P. S. A comprehensive survey on graph neural networks. arXiv preprint arXiv:1901.00596, 2021. DOI: 10.48550/arXiv.1901.00596.



Obrigada!



Gabriella Silveira Braz

10402554



Giovana Liao

10402264



Maria Julia de Pádua

10400630



Perguntas?